

第五章 优化程序性能

本章重点

- 熟练掌握普遍有用优化的方法
- 优化障碍（两个）
 - 理解函数调用为什么会阻碍优化
 - 理解内存别名的使用为什么会阻碍优化
- 循环展开
- 经典例题

目录

--本章PPT与书上内容互为补充

- 综述
- 普遍有用的优化方法
 - 代码移动/预先计算
 - 复杂运算简化Strength reduction
 - 公用子表达式的共享
 - 去掉不必要的过程调用
- 妨碍优化的因素Optimization Blockers（优化障碍）
 - 过程调用
 - 存储器别名使用Memory aliasing（不同名字指向相同内存）
- 运用指令级并行
- 处理条件

怎么优化源程序？

1. 更快 (**本课程重点！ 本章重点！**)
2. 更省 (存储空间、运行空间)
3. 更美 (UI 交互)
4. 更正确 (本课程重点！ 各种条件下)
5. 更可靠 (各种条件下的正确性、安全性)
6. 可移植
7. 更强大 (功能)
8. 更方便 (安装、使用、帮助/导航、可维护)
9. 更规范 (格式符合编程规范、接口规范)
10. 更易懂 (能读明白、有注释、模块化—清晰简洁)

关于性能的现实---性能比时间复杂度更重要

■ 常数因子也很重要!

- 代码编写不同，性能会差10倍!
- 要在多个层次进行优化:
 - 算法、 数据表示/结构、 过程、 循环（重点优化内循环）

■ 优化性能一定要理解“系统”

- 程序是怎样被编译和执行的---编译器友好的代码
 - 理解编译器的能力与局限性很重要!!!
- 现代处理器/存储系统是怎么运作的-CPU/RAM友好的代码
- 怎样测量程序性能、确定“瓶颈” -- **valgrind/gprof/Test Studio/Load Runner**
- 如何在不破坏代码模块性和通用性的前提下提高性能

优化编译器---编写编译器友好的代码！

- 提供从程序到机器的有效映射
 - 寄存器分配
 - 代码的选择与顺序
 - 消除死代码
 - 消除轻微的低效率问题
- 源程序稍变一下，编译器优化方式与性能变化很大
- （通常）不要提高渐进效率(asymptotic efficiency)
 - 由程序员来选择最佳的总体算法
 - 大O常常比常数因子更重要，但常数因子也很重要
- 难以克服“优化障碍”
 - 潜在的函数副作用
 - 潜在的内存别名使用

编译器优化的局限性

■ 在基本约束条件下运行

- 不能引起程序行为的任何改变
- 通常不会采取可能导致病态行为的优化

■ 对程序员来说很明显的行为，可能会因语言和编码风格而变得模糊/混乱

- 如：实际所需范围可能比所用变量类型对应的范围更小，多占内存

■ 低级别优化往往降低程序可读性和模块性

- 程序易出错，难以修改和扩展

低级别优化 (Low-Level Optimization) 通常指的是对程序进行详细的、接近硬件层面的优化，以提高程序的性能。然而，这种优化往往伴随着一些负面效应，如降低程序的可读性、模块性，增加出错的风险，以及使程序难以修改和扩展。

编译器优化的局限性

- 大多数分析只在过程范围内进行
 - 在大多数情况下，全程序分析过于昂贵
 - 新版本的GCC在单个文件中进行过程间分析
 - 但是, 不做文件间的代码分析
- 大多数分析都是基于静态信息的
 - 编译器很难预测运行时的输入
- 当有疑问时，编译器必须是保守的

普遍有用的优化

- 程序员或编译器应该做的优化

- 代码移动

- 减少计算执行的频率

如果它总是产生相同的结果，将代码从循环中移出

```
void set_row(double *a, double *b,  
            long i, long n)  
{  
    long j;  
    for (j = 0; j < n; j++)  
        a[n*i+j] = b[j];  
}
```



```
long j;  
int ni = n*i;  
for (j = 0; j < n; j++)  
    a[ni+j] = b[j];
```

编译器生成的代码移动 (-O1)

```
void set_row(double *a, double *b, long i, long n)
{
    long j;
    for (j = 0; j < n; j++)
        a[n*i+j] = b[j];
}
```

```
long j;
long ni = n*i;
double *rowp = a+ni;
for (j = 0; j < n; j++)
    *rowp++ = b[j];
```

优化后的等价C代码

优化后的汇编代码

```
set_row:
    testq    %rcx, %rcx           # Test n
    jle      .L1                 # If 0, goto done
    imulq    %rcx, %rdx           # ni = n*i
    leaq     (%rdi,%rdx,8), %rdx  # rowp = a + ni*8
    movl     $0, %eax            # j = 0
.L3:
    movsd    (%rsi,%rax,8), %xmm0 # t = b[j]
    movsd    %xmm0, (%rdx,%rax,8) # M[a+ni*8 + j*8] = t
    addq     $1, %rax             # j++
    cmpq     %rcx, %rax          # j:n
    jne      .L3                 # if !=, goto loop
.L1:
    rep ; ret                     # done:
```

复杂运算简化 Reduction in Strength

- 用更简单的方法替换昂贵的操作
- 移位、加，替代乘法/除法

$$16 * x \quad \rightarrow \quad x \ll 4$$

- 实际效果依赖于机器，取决于乘法或除法指令的成本
 - Intel Nehalem CPU整数乘需要3个CPU周期

```
for (i = 0; i < n; i++) {
  int ni = n*i;
  for (j = 0; j < n; j++)
    a[ni + j] = b[j];
}
```



```
int ni = 0;
for (i = 0; i < n; i++) {
  for (j = 0; j < n; j++)
    a[ni + j] = b[j];
  ni += n; // 用加来替代乘
}
```

共享公用子表达式

- 重用表达式的一部分
- GCC 使用 `-O1` 选项实现这个优化

```
/* Sum neighbors of i,j */
up =    val[(i-1)*n + j  ];
down =  val[(i+1)*n + j  ];
left =  val[i*n      + j-1];
right = val[i*n      + j+1];
sum = up + down + left + right;
```

3 乘法: $i*n$, $(i-1)*n$, $(i+1)*n$

```
leaq  1(%rsi), %rax  # i+1
leaq  -1(%rsi), %r8  # i-1
imulq %rcx, %rsi    # i*n
imulq %rcx, %rax    # (i+1)*n
imulq %rcx, %r8     # (i-1)*n
addq  %rdx, %rsi    # i*n+j
addq  %rdx, %rax    # (i+1)*n+j
addq  %rdx, %r8     # (i-1)*n+j
```

```
long inj = i*n + j;
up =    val[ inj - n];
down =  val[ inj + n];
left =  val[ inj - 1];
right = val[ inj + 1];
sum = up + down + left + right;
```

1 乘法: $i*n$

```
imulq  %rcx, %rsi  # i*n
addq    %rdx, %rsi # i*n+j
movq    %rsi, %rax # i*n+j
subq    %rcx, %rax # i*n+j-n
leaq    (%rsi,%rcx), %rcx # i*n+j+n
```


妨碍优化的因素/优化障碍#1: 函数调用

■ 将字符串转换为小写的函数

```
void lower(char *s)
{
    size_t i;
    for (i = 0; i < strlen(s); i++)
        if (s[i] >= 'A' && s[i] <= 'Z')
            s[i] -= ('A' - 'a');
}
```

小写转换性能

- 当字符串长度双倍时，时间增加了四倍
- 二次方（平方）的性能Quadratic performance



把循环变成 Goto形式--- 类汇编实现

```
void lower(char *s){
    size_t i = 0;
    if (i >= strlen(s))
        goto done;
loop:
    if (s[i] >= 'A' && s[i] <= 'Z')
        s[i] -= ('A' - 'a');
    i++;
    if (i < strlen(s))
        goto loop;
done:
}
```

```
/* My version of strlen */
size_t strlen(const char *s)
{
    size_t length = 0;
    while (*s != '\0') {
        s++;
        length++;
    }
    return length;
}
```


- **strlen每次循环都要重复执行**
- **strlen 性能**
 - 确定字符串长度的唯一方法是扫描它的整个长度，查找null字符
- **整体性能，长度为N的字符串**
 - N 次调用 strlen
 - 整体 $O(N^2)$ 性能

提高性能

```
void lower(char *s)
{
    size_t i;
    size_t len = strlen(s);
    for (i = 0; i < len; i++)
        if (s[i] >= 'A' && s[i] <= 'Z')
            s[i] -= ('A' - 'a');
}
```

- 代码移动：把调用 strlen 移到循环外
- 根据：从一次迭代到另一次迭代，strlen返回结果不会变化

Lower 小写转换的效率



- 字符串长度2倍时，时间也2倍
- `lower2` 的线性效率

妨碍优化的因素: 函数调用

■ 为什么编译器不能将`strlen`从内层循环中移出呢?

- 函数可能有副作用
 - 例如: 每次被调用都改变全局变量/状态
- 对于给定的参数, 函数可能返回不同的值
 - 依赖于全局状态/变量的其他部分
 - 函数`lower`可能与 `strlen` 相互作用

■ Warning:

- 编译器将函数调用视为黑盒
- 在函数附近进行弱优化

■ 补救措施:

- 使用 `inline` 内联函数
 - 用 `-O1` 时GCC这样做, 但局限于单一文件之内
- 程序员自己做代码移动

```
size_t lencnt = 0;
size_t strlen(const char *s)
{
    size_t length = 0;
    while (*s != '\0') {
        s++; length++;
    }
    lencnt += length;
    return length;
}
```

妨碍优化的因素#2: 内存别名使用

■ 别名使用

- 两个不同的内存引用指向相同的位置
- C很容易发生
 - 因为允许做地址运算
 - 直接访问存储结构
- 养成引入局部变量的习惯
 - 在循环中累积

内存的麻烦

```
/* Sum rows is of n X n matrix a
   and store in vector b */
void sum_rows1(double *a, double *b, long n) {
    long i, j;
    for (i = 0; i < n; i++) {
        b[i] = 0;
        for (j = 0; j < n; j++)
            b[i] += a[i*n + j];
    }
}
```

sum_rows1 inner loop

.L4:

```
movsd  (%rsi,%rax,8), %xmm0# FP load
addsd  (%rdi), %xmm0      # FP add
movsd  %xmm0, (%rsi,%rax,8)# FP store
addq   $8, %rdi
cmpq   %rcx, %rdi
jne    .L4
```

- 代码每次循环都更新 **b[i]**
- 为什么编译器不能优化这个？

内存别名使用Memory Aliasing

```

/* Sum rows is of n X n matrix a
   and store in vector b */
void sum_rows1(double *a, double *b, long n) {
    long i, j;
    for (i = 0; i < n; i++) {
        b[i] = 0;
        for (j = 0; j < n; j++)
            b[i] += a[i*n + j];
    }
}

```

```

double A[9] =
{ 0, 1, 2,
  4, 8, 16,
  32, 64, 128};
double B[3];
sum_rows1(A, A+3, 3);

```

- 代码每次循环都更新 **b[i]**
- 必须考虑这些更新会影响程序行为的可能性

Value of **b**:

init: [4, 8, 16]

i = 0: [3, 8, 16]

i = 1: [3, ? , ?]

i = 2: [3, ? , ?]

内存别名使用Memory Aliasing

```
/* Sum rows is of n X n matrix a
   and store in vector b */
void sum_rows1(double *a, double *b, long n) {
    long i, j;
    for (i = 0; i < n; i++) {
        b[i] = 0;
        for (j = 0; j < n; j++)
            b[i] += a[i*n + j];
    }
}
```

```
double A[9] =
{ 0, 1, 2,
  4, 8, 16,
  32, 64, 128};
double B[3];
sum_rows1(A, A+3, 3);
```

此时,
b[0]就是a[3]

- 代码每次循环都更新 b[i]
- 必须考虑这些更新会影响程序行为的可能性

i=0时: $b[0] = 0 + 1 + 2 = 3$, 此时 $b[0] = a[3] = 3$;
i=1时: $b[1]$ 初始化为0, 开始循环
 $b[1] += a[3]$ (此时 $a[3] = 3$) 则 $b[1] = 0 + 3 = 3$;
此时 $b[1] = 3$, 意味着 $a[4] = 3$;
所以 $b[1] += a[4]$ 推出 $b[1] = 3 + 3 = 6$;
继续 $b[1] += a[5]$ 推出 $b[1] = 6 + 16 = 22$;
此时 $b[1] = a[4] = 22$;
i=2 $b[2] = 32 + 64 + 128 = 224$, 此时 $b[2] = a[5] = 224$;

Value of **b**:

init: [4, 8, 16]

i = 0: [3, 8, 16]

i = 1: [3, 22, 16]

i = 2: [3, 22, 224]

与原本期望值 [3, 28, 224] 有差别

移除内存别名

```

/* Sum rows is of n X n matrix a
   and store in vector b */
void sum_rows2(double *a, double *b, long n) {
    long i, j;
    for (i = 0; i < n; i++) {
        double val = 0;
        for (j = 0; j < n; j++)
            val += a[i*n + j];
        b[i] = val;
    }
}

```

sum_rows2 inner loop

.L10:

```

    addsd  (%rdi), %xmm0 # FP load + add
    addq   $8, %rdi
    cmpq   %rax, %rdi
    jne    .L10

```

- 而且不需要存储中间结果

表示程序性能


- CPE: 每个元素的周期数(Cycles Per Element)
- 表示向量或列表操作的程序性能的方便方式
- $\text{Length} = n$
- In our case: **CPE = cycles per OP**
- $T = \text{CPE} * n + \text{经常开销(Overhead)}$
 - CPE 是线的斜率slope

“经常开销”是指在系统运行过程中，除了主要任务之外的固定额外开销。它可能来自初始化、清理、上下文切换、通信、管理等多个方面。它是一个常数项，表示与任务数量无关的额外成本或时间开销。

CPE: 例子

```
1  /* Compute prefix sum of vector a */
2  void psum1(float a[], float p[], long n)
3  {
4      long i;
5      p[0] = a[0];
6      for (i = 1; i < n; i++)
7          p[i] = p[i-1] + a[i];
8  }
9
10 void psum2(float a[], float p[], long n)
11 {
12     long i;
13     p[0] = a[0];
14     for (i = 1; i < n-1; i+=2) {
15         float mid_val = p[i-1] + a[i];
16         p[i]          = mid_val;
17         p[i+1]        = mid_val + a[i+1];
18     }
19     /* For even n, finish remaining element */ 此时, i=n-1
20     if (i < n)
21         p[i] = p[i-1] + a[i];
22 }
```

CPE




程序示例: 向量的数据类型

```
/* data structure for vectors */
typedef struct{
    size_t len;
    data_t *data;
} vec;
```

定义一个指针: `vec* vec_ptr`

■ 数据类型

- 使用 `data_t` 的不同声明
- `int`
- `long`
- `float`
- `double`



```
/* retrieve vector element
   and store at val */
int get_vec_element
(*vec v, size_t idx, data_t *val )
{
    if ( idx >= v->len )
        return 0;
    *val = v->data[idx];
    return 1;
}
```

程序示例的计算

```
void combine1(vec_ptr v, data_t *dest){  
    long int i;  
    *dest = IDENT;  
    for (i = 0; i < vec_length(v); i++) {  
        data_t val;  
        get_vec_element(v, i, &val);  
        *dest = *dest OP val;  
    }  
}
```

计算向量元素的
和或积

■ 数据类型

- 使用 data_t 的不同声明
- int
- long
- float
- double

■ 操作

- 使用 OP 和 IDENT 的不同定义
- + / 0 (op为+时IDENT为0)
- * / 1 (op为*时IDENT为1)

编译优化选项介绍

•O0（无优化）：

编译器在O0选项下不会对代码进行任何优化，其主要目标是尽量缩短编译时间和内存占用。在这种模式下，编译器会尽量保持代码的原始结构，调试工具（如debugger）能够准确地反映程序的预期行为。当程序运行时，开发者可以在调试器中断点处对变量进行赋值，或者将程序计数器跳转到函数内的其他语句，从而从源代码中精确地获取预期结果。这种模式非常适合开发和调试阶段，因为它能够确保代码的可读性和调试的准确性。

•O1（轻度优化）：

O1选项会在不显著增加编译时间和内存占用的前提下，对代码进行一些基本优化。它主要针对代码的分支结构、常量表达式等进行简化和优化，从而在一定程度上提高程序的运行效率。这种优化程度适合对性能要求不高，但又希望代码有一定优化的场景。

•O2（中度优化）：

O2选项会尝试更多的寄存器级和指令级优化。编译器会更积极地利用寄存器来存储变量和中间结果，同时对指令序列进行调整和优化，以提高程序的运行速度。然而，这些优化会增加编译时间和内存占用。O2是较为常用的优化级别，它在性能提升和编译成本之间取得了较好的平衡。

•O3（高级优化）：

O3选项在O2的基础上进一步增加了优化程度。它会使用更复杂的优化技术，例如伪寄存器网络、普通函数的内联展开以及针对循环的高级优化（如循环展开、循环融合等）。这些优化可以显著提高程序的性能，但也会大幅增加编译时间和内存占用。O3适用于对性能要求极高的场景，但开发者需要权衡编译成本和运行效率之间的关系。

•Os（优化代码大小）：

Os选项主要关注代码的体积优化，目标是生成更小的可执行文件。它会通过消除冗余代码、合并函数等方式减少代码大小，但可能会牺牲一定的运行效率。这种优化适用于嵌入式系统或对存储空间有限制的场景。

程序示例的性能（CPE度量值）

```
void combine1(vec_ptr v, data_t *dest)
{
    long int i;
    *dest = IDENT;
    for (i = 0; i < vec_length(v); i++) {
        data_t val;
        get_vec_element(v, i, &val);
        *dest = *dest OP val;
    }
}
```

计算向量元素的
和或积

方法	Integer		Double FP	
操作 OP	+	*	+	*
Combine1 未优化	22.68	20.02	19.98	20.18
Combine1 -O1	10.12	10.12	10.17	11.14

基础/简单优化

```
void combine1(vec_ptr v, data_t *dest)
{
    long int i;
    *dest = IDENT;
    for (i = 0; i < vec_length(v); i++) {
        data_t val;
        get_vec_element(v, i, &val);
        *dest = *dest OP val;
    }
}
```

```
void combine4(vec_ptr v, data_t *dest)
{
    long i;
    long    length = vec_length(v);
    data_t  *d = get_vec_start(v);
    data_t  t = IDENT; //局部变量累计结果
    for (i = 0; i < length; i++)
        t = t OP d[i]; //消除不必要的内存引用
    *dest = t;
}
```

- 把函数vec_length移到循环外
- 避免每个循环的边界检查
- 用临时/局部变量累积结果

```
int get_vec_element
(*vec v, size_t idx, data_t *val)
{
    if ( idx >= v->len ) 边界检查
        return 0;
    *val = v->data[idx];
    return 1;
}
```

基础/简单优化的效果

```
void combine4(vec_ptr v, data_t *dest){
    long i;
    long length = vec_length(v);
    data_t *d = get_vec_start(v);
    data_t t = IDENT;
    for (i = 0; i < length; i++)
        t = t OP d[i];
    *dest = t;
}
```

方法	Integer		Double FP	
操作OP	+	*	+	*
Combine1 -O1	10.12	10.12	10.17	11.14
Combine4	1.27	3.01	3.01	5.01

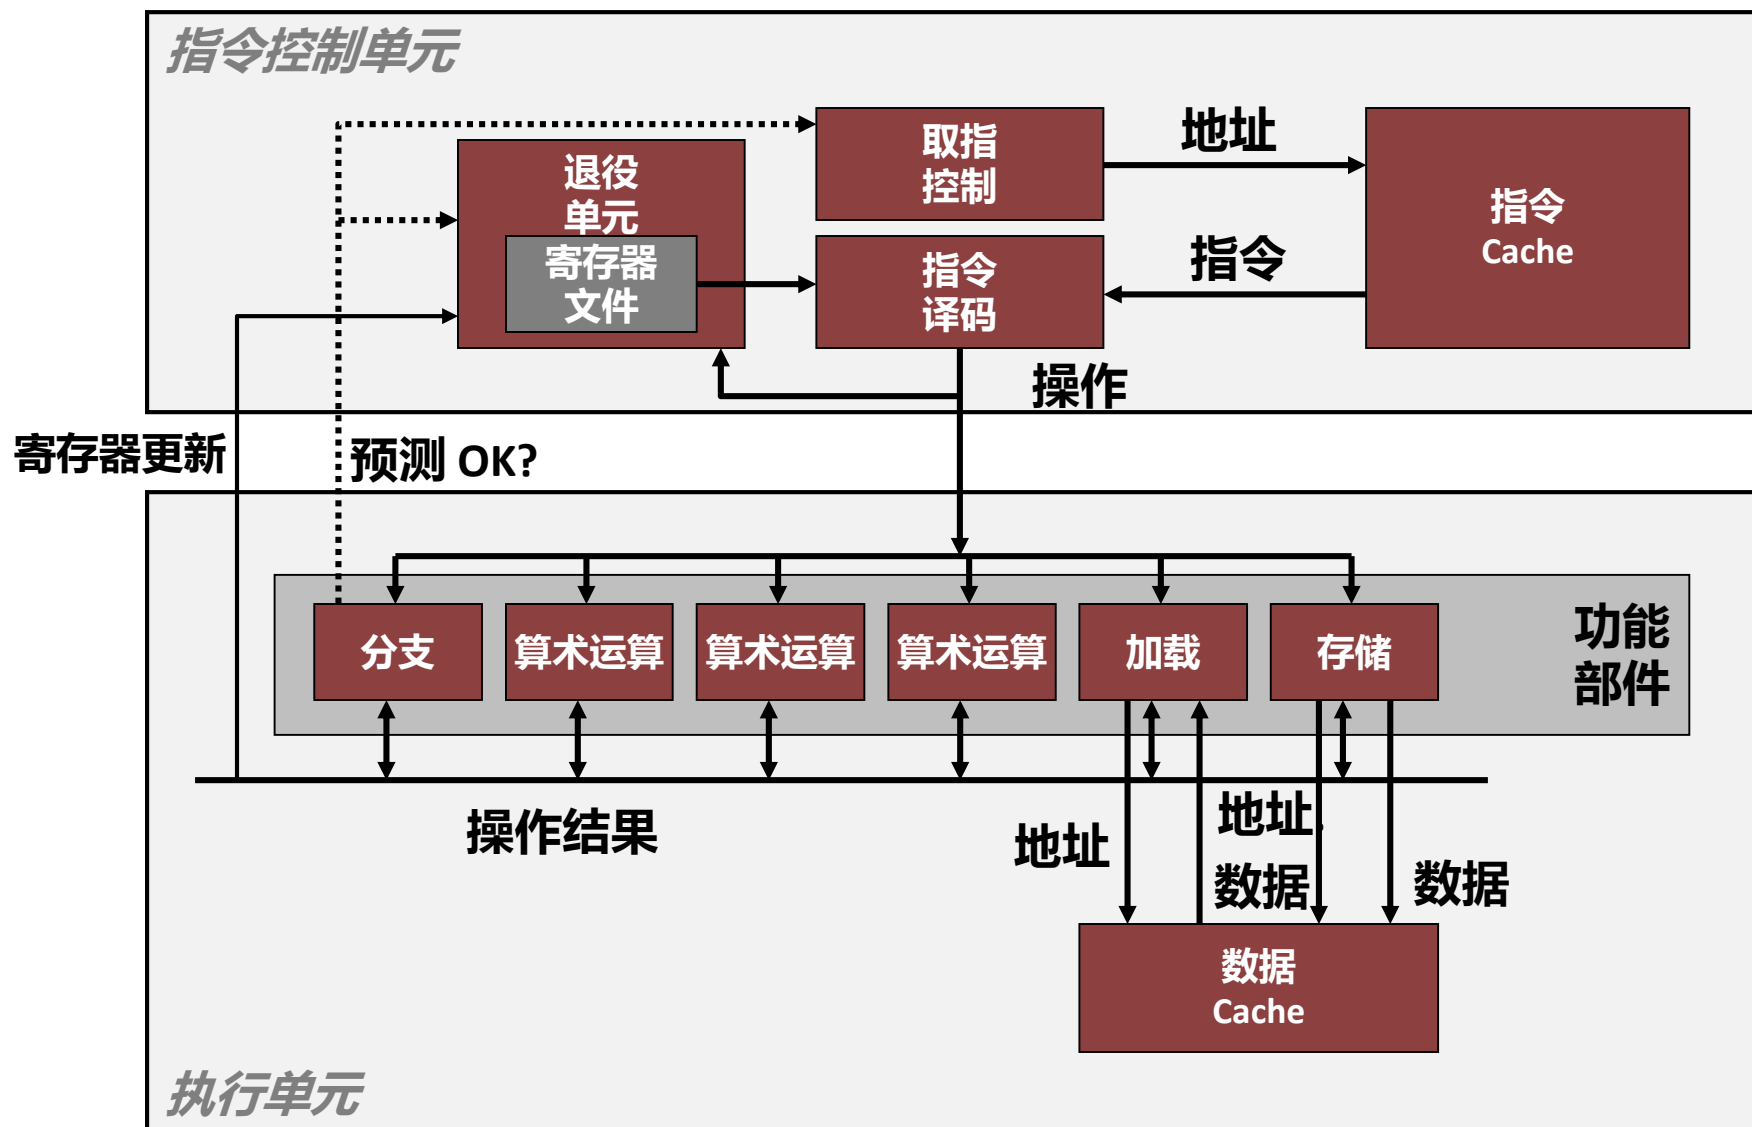
- 消除循环中大量开销的来源sources of overhead

利用指令级并行进行优化

- 需要理解现代处理器的设计
 - 硬件可以并行执行多个指令
- 性能受数据依赖（比如冒险）的限制
- 简单的转换可以带来显著的性能改进
 - 编译器通常无法进行这些转换
 - 浮点运算缺乏结合性和可分配性

指令级并行 (Instruction-Level Parallelism, ILP) 是一种通过重新排列或调整指令的执行顺序, 以充分利用处理器的多条执行流水线, 从而提高程序运行效率的技术。通过简单的转换 (如指令调度、循环展开等), 可以显著减少处理器的空闲时间, 提高指令吞吐量, 从而带来显著的性能改进。

现代CPU设计-超标量




超标量Superscalar处理器

- **定义:** 一个周期执行多条指令。 这些指令是从一个连续的指令流获取的, 通常被动态调度的。
- **好处:** 不需要编程的努力, 超标量处理器可以利用大多数程序所具有的指令级并行性。
- 大多数现代的CPU都是超标量
- Intel: 从Pentium (1993)起

流水线功能单元

```
long mult_eg(long a, long b, long c) {
    long p1 = a*b;
    long p2 = a*c;
    long p3 = p1 * p2;
    return p3;
}
```



Time							
	1	2	3	4	5	6	7
阶段 1	a*b	a*c			p1*p2		
阶段 2		a*b	a*c			p1*p2	
阶段 3			a*b	a*c			p1*p2

- 把计算分解为多个阶段
- 一个阶段又一个阶段地通过各部分计算
- 一旦值传送给 $i+1$ ，阶段 i 就能开始新的计算，
- 例如，即使每个乘法需要3个周期，在7个周期里完成3个乘法

Haswell 架构的CPU

- 8 个功能单元—P359
- 可并行执行多条指令

2 个加载，带地址计算

1 个存储，带地址计算

4 个整数运算

2 个浮点乘法运算

1 个浮点加法

1 个浮点除法

容量：能够执行该运算的功能单元数

延迟：完成运算所需要的总clk（时钟周期）

发射时间：连续同类型运算间最小clk

- 某些指令 > 1 周期,但能够被流水 P361

指令	延迟Latency	周期/发射
Load / Store	4	1
Integer 乘法	3	1
Integer/Long 除法	3-30	3-30
Single/Double FP 乘法	5	1
Single/Double FP 加法	3	1
Single/Double FP 除法	3-15	3-15

运算	整数			浮点数		
	延迟	发射	容量	延迟	发射	容量
加法	1	1	4	3	1	1
乘法	3	1	1	5	1	2
除法	3 ~ 30	3 ~ 30	1	3 ~ 15	3 ~ 15	1

图 5-12 参考机的操作的延迟、发射时间和容量特性。延迟表明执行实际运算所需要的时钟周期总数，而发射时间表明两次运算之间间隔的最小周期数。容量表明同时能发射多少个这样的操作。除法需要的时间依赖于数据值

```

1  /* Accumulate result in local variable */
2  void combine4(vec_ptr v, data_t *dest)
3  {
4      long i;
5      long length = vec_length(v);
6      data_t *data = get_vec_start(v);
7      data_t acc = IDENT;
8
9      for (i = 0; i < length; i++) {
10         acc = acc OP data[i];
11     }
12     *dest = acc;
13 }

```

Combine4-P355的x86-64 编译

■ 内循环(做整数乘法) $acc = acc \text{ OP } data[i]$

.L519:	# Loop:
imull (%rax,%rdx,4), %ecx	# t = t * d[i]
addq \$1, %rdx	# i++
cmpq %rdx, %rbp	# Compare length:i
jg .L519	# If >, goto Loop

方法	Integer		Double FP	
操作	+	*	+	*
Combine4	1.27	3.01	3.01	5.01
延迟界限	1.00	3.00	3.00	5.00

延迟界限：任何必须按照严格顺序完成合并运算的函数所需的最小CPE值（等于单独完成每次操作需要的时钟周期）


Combine4 = 串行计算(操作OP = *)

■ 计算 (向量长度=8)

$$(((((((1 * d[0]) * d[1]) * d[2]) * d[3]) * d[4]) * d[5]) * d[6]) * d[7])$$

■ 顺序依赖性 Sequential dependence

- 性能: 由OP的延迟决定



循环展开Loop Unrolling 2x1 (步长为2, 1路展开)

```
void unroll2a_combine(vec_ptr v, data_t *dest)
{
    long length = vec_length(v);
    long limit = length-1;
    data_t *d = get_vec_start(v);
    data_t x = IDENT;
    long i;
    /* Combine 2 elements at a time */
    for (i = 0; i < limit; i+=2) {
        x = (x OP d[i]) OP d[i+1];
    }
    /* Finish any remaining elements */
    for (; i < length; i++) {
        x = x OP d[i];
    }
    *dest = x;
}
```

此时, $i=length-1$

- 每个循环 运行 2倍的更有用的工作, 即多做了一个OP

循环展开的效果

方法	Integer		Double FP	
操作	+	*	+	*
Combine4	1.27	3.01	3.01	5.01
2x1循环展开	1.01	3.01	3.01	5.01
延迟界限	1.00	3.00	3.00	5.00

$$x = (x \text{ OP } d[i]) \text{ OP } d[i+1];$$

- 对整数 + 有帮助
 - 达到延迟界限
- 其他没有改进, *Why?*
 - 仍然是顺序依赖

在原始代码中, 每次循环迭代都需要进行循环控制 (如循环计数、条件判断等), 这些操作会消耗额外的时钟周期。通过循环展开 (比如本例的2x1循环展开), 可以减少循环控制的次数, 从而提高效率。

带重组Reassociation的循环展开 (2x1a)

```
void unroll2aa_combine(vec_ptr v, data_t *dest)
{
    long length = vec_length(v);
    long limit = length-1;
    data_t *d = get_vec_start(v);
    data_t x = IDENT;
    long i;
    /* Combine 2 elements at a time */
    for (i = 0; i < limit; i+=2) {
        x = x OP (d[i] OP d[i+1]);
    }
    /* Finish any remaining elements */
    for (; i < length; i++) {
        x = x OP d[i];
    }
    *dest = x;
}
```

Compare to before

$x = (x \text{ OP } d[i]) \text{ OP } d[i+1];$

- 这能改变运算结果吗?
- 是的, 对 FP浮点数. *Why?* 浮点数加法和乘法不满足结合律

重组的效果/影响

方法	Integer		Double FP	
操作OP	+	*	+	*
Combine4	1.27	3.01	3.01	5.01
循环展开 2x1	1.01	3.01	3.01	5.01
循环展开 2x1a	1.01	1.51	1.51	2.51
延迟界限	1.00	3.00	3.00	5.00
吞吐量界限	0.50	1.00	1.00	0.50

整数加法的特性

整数加法的延迟通常非常低（1到2个时钟周期），这意味着单个加法操作本身并不会显著影响性能。因此，即使使用多个加法器，性能提升也可能不明显，原因如下：

• **低延迟特性**：整数加法的延迟已经很低，进一步优化的空间有限。

• **数据依赖关系**：x 的值仍然依赖于前一次加法的结果，这种依赖关系限制了并行化的程度。

• **硬件资源利用率**：现代处理器通常已经配备了多个整数加法器（超标量架构），并且通过流水线技术隐藏了部分延迟。进一步增加加法器数量带来的边际效益有限

吞吐量界限：CPE的最小界限

4 个整数加法功能单元
2 个加载功能单元

■ 接近 2 倍的速度提升：Int *, FP +, FP *


■ 原因：打破了顺序依赖

```
x = x OP (d[i] OP d[i+1]);
```

■ 为何是这样? (下一页)

2个浮点乘法功能单元
2个浮点加载功能单元

重组的计算（注意结合律不一定合理）

$$x = x \text{ OP } (d[i] \text{ OP } d[i+1]);$$


- 什么改变了:
 - 下一个循环的操作可以早一些开始 (没有依赖)

- 整体性能
 - N 个元素, 每个操作 D 个周期延迟
 - $(N/2+1)*D$ cycles:
 $CPE = D/2$

循环展开：使用分离的累加器 (2x2)

■ 重组的不同形式

```
void unroll2a_combine(vec_ptr v, data_t *dest)
{
    long length = vec_length(v);
    long limit = length-1;
    data_t *d = get_vec_start(v);
    data_t x0 = IDENT;
    data_t x1 = IDENT;
    long i;
    /* Combine 2 elements at a time */
    for (i = 0; i < limit; i+=2) {
        x0 = x0 OP d[i];
        x1 = x1 OP d[i+1];
    }
    /* Finish any remaining elements */
    for (; i < length; i++) {
        x0 = x0 OP d[i];
    }
    *dest = x0 OP x1;
}
```

分离的累加器的效果

方法	Integer		Double FP	
操作	+	*	+	*
Combine4	1.27	3.01	3.01	5.01
Unroll 2x1	1.01	3.01	3.01	5.01
Unroll 2x1a	1.01	1.51	1.51	2.51
Unroll 2x2	0.81	1.51	1.51	2.51
延迟界限	1.00	3.00	3.00	5.00
吞吐量界限	0.50	1.00	1.00	0.50


- 整数加 + 同时使用了两个加载单元

```
x0 = x0 OP d[i];
x1 = x1 OP d[i+1];
```

- 2倍速度提升 : Int *, FP +, FP *

分离的累加器

```
x0 = x0 OP d[i];
x1 = x1 OP d[i+1];
```



■ 什么改变了:

- 两个独立的操作的“流水”

■ 整体性能

- N 个元素, 每个操作 D 个周期延迟
- 应为 $(N/2+1)*D$ cycles:
CPE = D/2
- CPE与预测匹配!

循环展开 & 累加

- 设想对元素 i 到 $i+k-1$ 合并运算
- 能循环展开到任一程度 L 吗？
 - 能够并行累加 K 个结果吗？
 - K 是 L 的倍数
- 只有保持能够执行该操作的所有功能单元的流水线都是满的，程序才能达到这个操作的吞吐量界限。 $K \geq C \text{容量} * L \text{延迟}$
- 限制
 - 效果/收益递减 Diminishing returns
 - 不能超出执行单元的吞吐量限制
 - 长度小开销大 Large overhead for short lengths
 - 顺序地完成循环

K : 表示需要同时进行的独立操作的数量(即并行度)

C : 表示每个功能单元的容量(即每个功能单元一次可以处理的操作数量)

L : 表示操作的延迟(即完成一个操作所需的时钟周期数)

循环展开因子(Loop Unrolling Factor) K : 是指在循环展开优化中，将循环体中的多个迭代合并到一个迭代中的数量。循环展开是一种编译器优化技术，通过减少循环控制开销和增加指令级并行度来提高程序性能。

2. 并行累加 K 个结果

假设我们希望并行累加 K 个结果，其中 K 是展开程度 L 的倍数。例如，如果 $L = 4$ 且 $K = 8$ ，那么可以将循环展开为：

c

复制

```
for (i = 0; i < n; i += 8) {  
    temp1 = d[i] + d[i+1] + d[i+2] + d[i+3];  
    temp2 = d[i+4] + d[i+5] + d[i+6] + d[i+7];  
    x = x + temp1 + temp2;  
}
```

在这种情况下，如果处理器有足够的加法器（例如两个加法器），那么可以并行执行 `temp1` 和 `temp2` 的计算。

3. 公式 $K \geq C \times L$ 的解释

- K ：表示需要同时进行的独立操作的数量（即并行度）。
- C ：表示每个功能单元的容量（即每个功能单元一次可以处理的操作数量）。
- L ：表示操作的延迟（即完成一个操作所需的时钟周期数）。

为了达到某个操作的最大吞吐量，需要满足 $K \geq C \times L$ 。这意味着，为了隐藏延迟并达到最大吞吐量，需要有足够的并行操作来填满所有功能单元的流水线。

循环展开 & 累加: Double *

■ 案例

- Intel Haswell
- Double FP 乘法
- 延迟界限: 5.00. 吞吐量界限: 0.50

Accumulators	FP *	L							
	K	1	2	3	4	6	8	10	12
	1	5.01	5.01	5.01	5.01	5.01	5.01	5.01	
	2		2.51		2.51		2.51		
	3			1.67					
	4				1.25		1.26		
	6					0.84			0.88
	8						0.63		
	10							0.51	
	12								0.52

循环展开 & 累加: Int +

■ 案例

- Intel Haswell
- Integer 加法
- 延迟界限: 1.00. 吞吐量界限: 0.50

Accumulators	INT+	L							
	K	1	2	3	4	6	8	10	12
	1	1.27	1.01	1.01	1.01	1.01	1.01	1.01	
	2		0.81		0.69		0.54		
	3			0.74					
	4				0.69		1.24		
	6					0.56			0.56
	8						0.54		
	10							0.54	
	12								0.56

可得到的性能








- 只受功能单位的吞吐量限制
- 比原始的、未优化的代码提高了42倍

方法	Integer		Double FP	
操作	+	*	+	*
最好Best	0.54	1.01	1.01	0.52
延迟界限	1.00	3.00	3.00	5.00
吞吐量界限	0.50	1.00	1.00	0.50

方法	Integer		Double FP	
操作 OP	+	*	+	*
Combine1 未优化	22.68	20.02	19.98	20.18
Combine1 -O1	10.12	10.12	10.17	11.14

用 AVX2 编程


YMM 寄存器：16 个，每个32字节

- 32个单字节整数 
- 16个 16位整数 
- 8 个 32位整数 
- 8 个单精度浮点数 
- 4 个双精度浮点数 
- 1个单精度浮点数 
- 1 个双精度浮点数 

SIMD 操作


■ SIMD 操作: 单精度

`vaddsd %ymm0, %ymm1, %ymm1`



■ SIMD 操作: 双精度

`vaddpd %ymm0, %ymm1, %ymm1`



使用向量指令

方法	Integer		Double FP	
操作	+	*	+	*
标量 Best	0.54	1.01	1.01	0.52
向量 Best	0.06	0.24	0.25	0.16
延迟界限	1.00	3.00	3.00	5.00
吞吐量界限	0.50	1.00	1.00	0.50
向量 吞吐量界限	0.06	0.12	0.25	0.12

■ 使用AVX 指令

- 多数据元素的并行操作
- 看网络旁注 OPT:SIMD on CS:APP web 页面

分支怎么处理?

■ 挑战

- 在**执行单元**前，**指令控制单元**必须工作好，以生成足够的操作来使EU保持繁忙

```
404663: mov    $0x0,%eax
```

```
404668: cmp    (%rdi),%rsi
```

```
40466b: jge    404685 ←
```

```
40466d: mov    0x8(%rdi),%rax
```

```
...
```

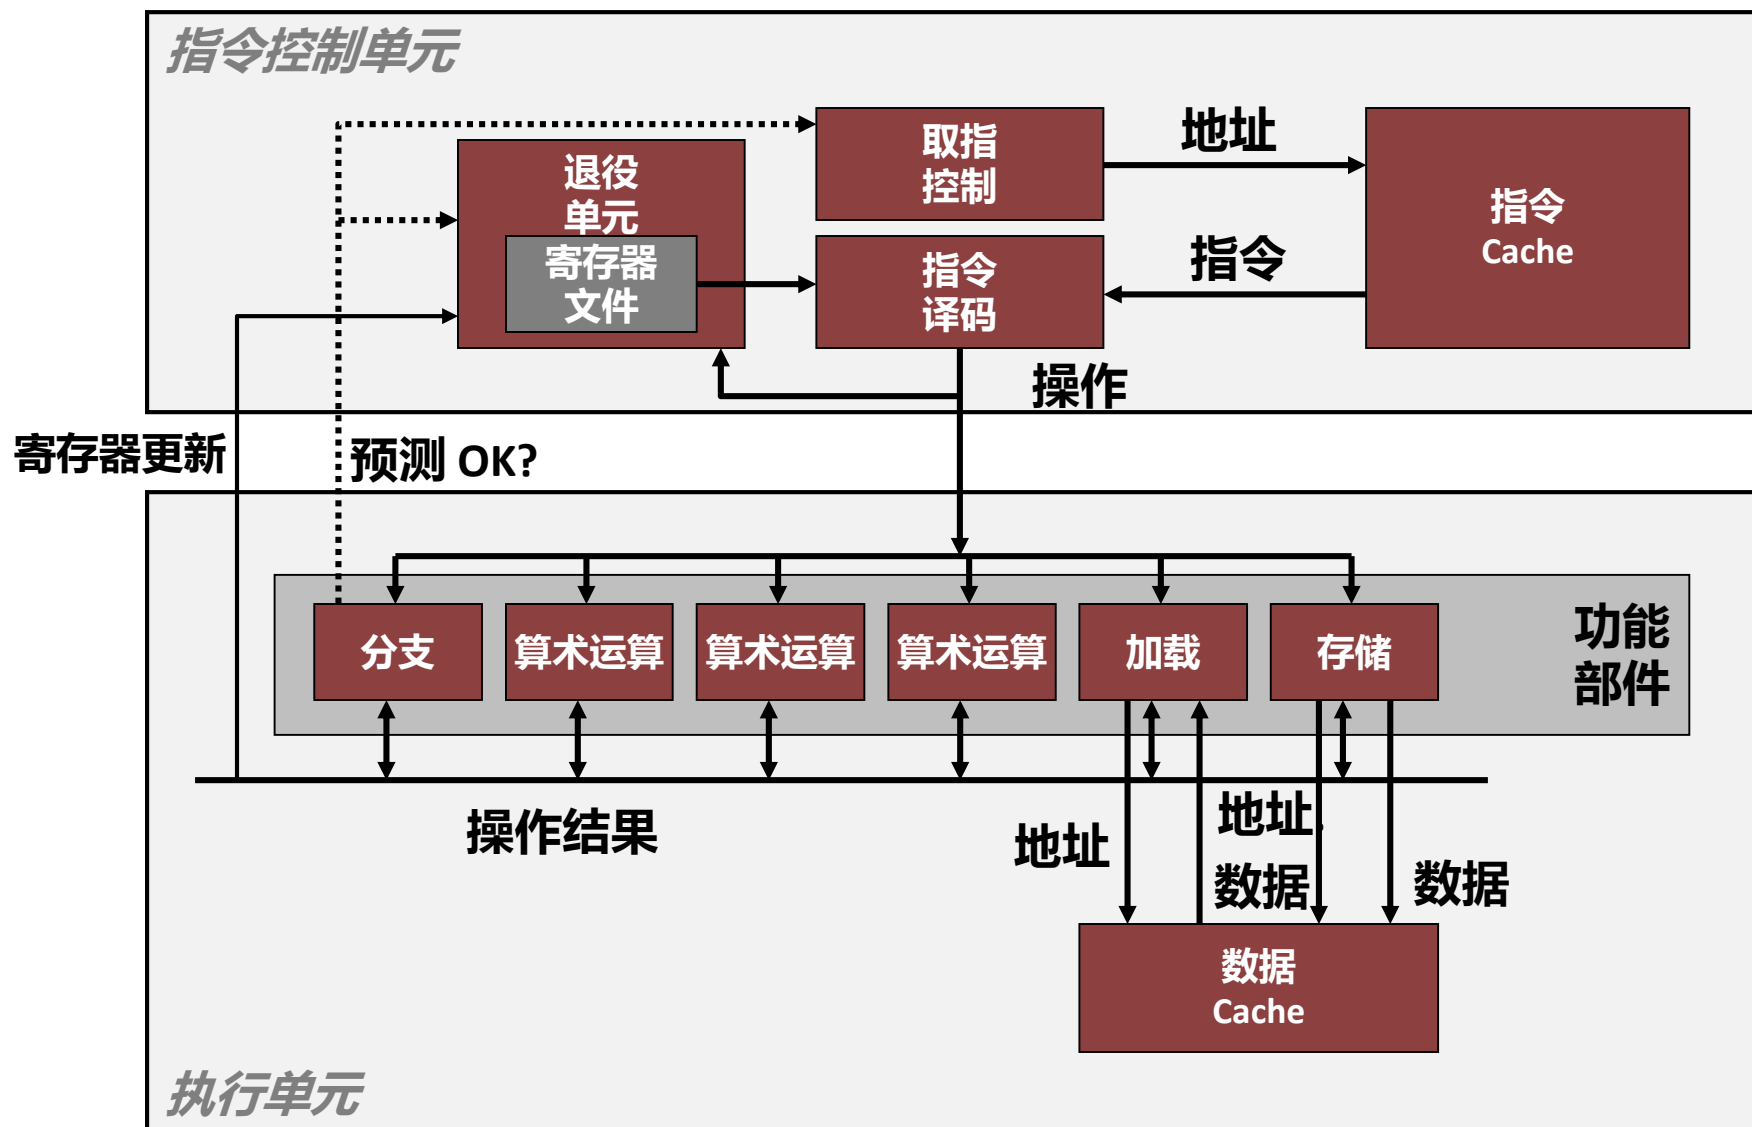
```
404685: repz retq
```

} Executing

How to continue?

- 遇到条件分支时，无法可靠地确定继续取指的位置

现代CPU设计



分支的结果

- 当遇到条件分支时，无法确定继续取指的位置
 - 选择分支:将控制转移到分支目标
 - 不选择分支:继续下一个指令
- 直到分支/整数单元的结果确定后 才能解决

```
404663:  mov    $0x0,%eax
404668:  cmp    (%rdi),%rsi
40466b:  jge    404685
40466d:  mov    0x8(%rdi),%rax
. . .
404685:  repz   retq
```

不选择分支

选择分支

分支预测

■ 设想

- 猜测会走哪个分支
- 在预测的位置开始执行指令
 - 但不要真修改寄存器或内存数据

```
404663:  mov    $0x0,%eax
404668:  cmp    (%rdi),%rsi
40466b:  jge    404685
40466d:  mov    0x8(%rdi),%rax

. . .

404685:  repz   retq
```

预测选择分支

开始执行

穿过循环的分支预测

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

*i = 98***假定****向量 (数组) 长度 = 100****预测选择分支(OK)**


```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

*i = 99***预测选择分支(Oops)**

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

*i = 100***读无效位置**

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

i = 101

vmulsd 是一条 x86-64 SIMD (单指令多数据) 指令, 属于 AVX (高级矢量扩展) 指令集。这条指令用于对双精度浮点数进行标量乘法操作。它允许你在单条指令中完成两个双精度浮点数的乘法, 从而提高计算效率。

分支错误预测的失效

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

i = 98

假定

向量长度 = 100

预测选择分支(OK)

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

i = 99

预测选择分支(Oops)

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

i = 100

无效

```
401029: vmulsd (%rdx), %xmm0, %xmm0
40102d: add    $0x8, %rdx
401031: cmp    %rax, %rdx
401034: jne    401029
```

i = 101

分支错误预测的恢复

```

401029:  vmulsd  (%rdx), %xmm0, %xmm0
40102d:  add     $0x8, %rdx
401031:  cmp     %rax, %rdx
401034:  jne     401029
401036:  jmp     401040
. . .
401040:  vmovsd  %xmm0, (%r12)

```

i = 99

绝对不会采纳

重新加载流水线

■ 性能开销

- 现代处理器上的多个时钟周期
- 可能是一个主要的性能限制器

怎么办？

- Intel的分支预测：太多了.....哭😞😞😞😞😞
- 条件true--分支正确正确率60%
- 距离为负---分支正确正确率80%
- 尽量少用分支！！！！！！能替换吗？
 - 1) 编程时提高跳转到预测正确分支的概率
 - 2) 用条件传送与条件运算指令
 - 3) Arm等嵌入式CPU（特有的条件执行指令）

高性能分支预测（回顾）

■ 影响性能的关键

- 处理预测错误通常需要11-15个周期

■ 分支目标缓存

- 512 个目的地址
- 4 bits 用于历史信息
- 自适应算法
 - 可以识别重复的模式，例如交替跳转或不跳转

■ 处理BTB未命中

（BTB：Branch Target Buffer，分支目标buffer）


- 在第六个周期检测
- 负偏移地址时采用预测，正偏移时不采用预测
 - 循环vs条件

分支预测示例（回顾）

■ 分支历史

- 编码分支指令先前的历史信息
- 预测是否采取分支

NT代表not true



■ 状态机

- 每次采取分支后，向右过渡
- 不采取则向左过渡
- 在状态 “Yes!” 或 “Yes?” 下，预测采取分支

获得高性能

- 搭配好的编译器和优化选项
- 编写高效算法
- 编写编译器友好的代码
 - 使用内联函数：减少函数调用开销。
 - 避免复杂的数据依赖：减少指令之间的数据依赖，提高指令级并行度。
 - 使用常量和宏：减少运行时的计算开销。
- 小心妨碍优化的因素：函数调用 & 存储器引用
- 仔细观察最内层的循环 (循环展开，减少循环控制开销)
- 为机器优化代码 (gcc中的-O2/O3)
 - 利用指令级并行
 - 避免不可预测的分支
 - 使代码能较好地缓存 (在后续的课程介绍)

经典例题

1. 优化如下程序，给出优化结果并说明理由。

```
int sum_array(int a[M][N][N]) //M、N足够大
{
    int i, j, k, sum = 0;
    for (i = 0; i < N; i++)
        for (j = 0; j < N; j++)
            for (k = 0; k < M; k++)
                sum += a[k][i][j];
    return sum;
}
```

本章主要以设计题考查，基本上一定会有个程序优化的大题。

参考答案

```
int sum_array(int a[M][N][N]) //M、N足够大
{
    int limit=N-1;
    int i, j, k, sum = 0;
    for (i = 0; i < M; i++){
        int *i_ptr = &a[i][0][0];
        for (j = 0; j < N; j++){
            int *j_ptr = i_ptr+j*N;
            for (k = 0; k < limit; k+=2)
                sum =sum + (*(j_ptr+k)+*(j_ptr+k+1));
            if(k < N)
                sum += *(j_ptr+k);
        }
    }
    return sum;
}
```

解答

- (1)一般优化：通过计算i_ptr,j_ptr减少第三层循环中的计算量。
- (2)面向编译器的优化：使用循环展开2x1，也可使用其他循环展开。
- (3)面向cache的优化：修改i,j,k的遍历顺序，使的cache的命中率尽可能地高。

运行时间比较：性能提升了2.53倍

机器：Intel (R) Core(TM) i7-8550U CPU @1.8GHz 1.99GHz

```
M = 100,N = 70
Runtime of v1 is : 0.001620 s
Runtime of v2 is : 0.000620 s
Process returned 0 (0x0)   execution time : 0.136 s
Press any key to continue.
```

```
M = 100,N = 60
Runtime of v1 is : 0.001020 s
Runtime of v2 is : 0.000400 s
Process returned 0 (0x0)   execution time : 0.090 s
Press any key to continue.
```

```
M = 70,N = 70
Runtime of v1 is : 0.001000 s
Runtime of v2 is : 0.000420 s
Process returned 0 (0x0)   execution time : 0.091 s
Press any key to continue.
```

***Hope you
enjoyed
the
CSAPP
course!***